

# Kooperativni pristup odlučivanju zasnovan na teoriji igara za fuziju klasifikatora u biomedicinskim sistemima

Milica Tomić  
Računarstvo i automatika - modul:  
Biomedicinsko inženjerstvo  
Univerzitet u Novom Sadu,  
Fakultet tehničkih nauka  
Novi Sad, Srbija  
[tomic.e29.2024@uns.ac.rs](mailto:tomic.e29.2024@uns.ac.rs)

Andrea Vaštag  
Računarstvo i automatika - modul:  
Biomedicinsko inženjerstvo  
Univerzitet u Novom Sadu,  
Fakultet tehničkih nauka  
Novi Sad, Srbija  
[andrea.vastag@uns.ac.rs](mailto:andrea.vastag@uns.ac.rs)

Lidija Renji  
Računarstvo i automatika - modul:  
Biomedicinsko inženjerstvo  
Univerzitet u Novom Sadu,  
Fakultet tehničkih nauka  
Novi Sad, Srbija  
[lidija.renji@uns.ac.rs](mailto:lidija.renji@uns.ac.rs)

Ana Mandić  
Računarstvo i automatika - modul:  
Biomedicinsko inženjerstvo  
Univerzitet u Novom Sadu,  
Fakultet tehničkih nauka  
Novi Sad, Srbija  
[mandic.e22.2024@uns.ac.rs](mailto:mandic.e22.2024@uns.ac.rs)

**Sažetak** — U ovom radu predstavljen je kooperativni pristup u klasifikaciji abnormalnosti krvnog pritiska primenom ansambl modela zasnovano na teoriji igara. Pojedinačni klasifikatori, *k* najbližih suseda (*kNN*), stablo odluke i mašine na bazi vektora nosača (*SVM*), modelovani su kao racionalni agenti koji kolektivno donose odluku kroz fuziju predikcija, uz ponderisanje na osnovu senzitivnosti svakog modela. Rezultati pokazuju da *fusion* model postiže veću pouzdanost od *kNN* i *SVM* modela u detekciji stvarno bolesnih ispitanika. Ovakav kooperativni pristup omogućava stabilnije i tačnije donošenje odluka u medicinskim sistemima, čime se povećava efikasnost preventivne dijagnostike.

**Glavne riječi** — krvni pritisak, baza podataka, primenjena teorija igara, kooperativna igra, *kNN*, *SVM*, stablo odluke, senzitivnost

## I. UVOD

Savremeni biomedicinski sistemi sve više se oslanjaju na metode mašinskog učenja za analizu fizioloških signala i donošenje odluka u realnom vremenu. Jedan od najvažnijih zadataka takvih sistema jeste tačno i pouzdano praćenje vitalnih funkcija, među kojima posebno mesto zauzima krvni pritisak kao ključni pokazatelj zdravlja kardiovaskularnog sistema.

Krvni pritisak predstavlja silu kojom krv deluje na zidove krvnih sudova tokom cirkulacije. Normalne vrednosti iznose približno 120/80 mmHg, dok odstupanja od tih vrednosti mogu ukazati na hipertenziju (povišen pritisak) ili hipotenziju (snižen pritisak). Obe pojave mogu dovesti do ozbiljnih zdravstvenih komplikacija kao što su srčani udar, moždani udar ili oštećenje organa. Zbog toga je pravovremena detekcija abnormalnosti krvnog pritiska od izuzetnog značaja za prevenciju i rano lečenje kardiovaskularnih bolesti.

Međutim, tačna detekcija i predikcija odstupanja krvnog pritiska predstavljaju izazov zbog prisustva šuma u podacima, varijabilnosti fizioloških signala i nedostatka jednoznačnih obrazaca. Pojedinačni klasifikatori često imaju ograničene performanse u takvim uslovima, što dovodi do potrebe za kombinovanjem više modela radi dobijanja stabilnije i pouzdanije odluke.

U radu "Ensemble Learning Approach via a Kalman Filtered Markov Model for a Passive Wearable Respiratory Monitor" autori su prikazali sistem koji kombinuje više klasifikatora i koristi Kalman filtriranje za smanjenje šuma i poboljšanje detekcije respiratornog stanja [1]. Iako je prvobitna primena bila u oblasti praćenja disanja, osnovni princip fuzije odluka više modela može se uspešno primeniti i u analizi abnormalnosti krvnog pritiska [1].

U ovom projektu ta ideja se posmatra kroz prizmu teorije igara. Svaki klasifikator tumači se kao racionalni agent (igrač) koji donosi odluku na osnovu sopstvenih informacija, a njihova međusobna saradnja (kooperacija) vodi ka zajedničkom cilju – povećanju ukupne tačnosti sistema. Na taj način, ensemble sistem postaje primena kooperativne teorije igara, gde zajednička strategija svih igrača donosi veći zbirni dobitak (*engl. payoff*) od pojedinačnog delovanja svakog klasifikatora. Ovaj pristup omogućava ne samo precizniju detekciju abnormalnosti krvnog pritiska, već i dublje razumevanje načina na koji različiti modeli uče, donose odluke i „pregovaraju“ unutar jednog sistema.

## II. METODE I MATERIJALI

### A. Baza podataka

Problem koji se rešava je predviđanje abnormalnosti krvnog pritiska na osnovu zdravstvenih i demografskih faktora, kao i životnog stila [2]. U pitanju je klasifikacioni problem sa 2 klase. U bazi ima 2000 uzoraka, od kojih u klasi 0 (normalan krvni pritisak) ima 50.65% uzoraka, dok u klasi 1 (prisutna abnormalnost) ima 49.35% uzoraka. Predikcija abnormalnosti krvnog pritiska se vrši na osnovu 13 obeležja, od kojih su 7 numeričkih: nivo hemoglobina, genetske predispozicije, starost, indeks telesne mase, fizička aktivnost, količina unosa alkohola po danu i nivo soli u ishrani i 6 kategoričkih: pol, trudnoća, nivo stresa, da li je pacijent pušač ili ne, da li postoji hronična bolest bubrega i da li postoji poremećaj nadbubrežne i štitne žlezde [2].

## B. Obrada baze i analiza podataka

### 1) Irelevantne, nedostajuće i nevalidne vrednosti

Pre svega, analiziran je uticaj svakog pojedinačnog obeležja na postojeći problem i ustanovljeno je da se može izbaciti redni broj pacijenta, s obzirom na to da predstavlja samo jedinstveni identifikator pacijenta i ne doprinosi analizi.

Obeležja koja imaju nedostajuće vrednosti su:

- Genetske predispozicije – 4.6%
- Trudnoća – 77.9%
- Količina unosa alkohola po danu – 12.1%

Nedostajuće vrednosti za trudnoću su rešene izbacivanjem tog obeležja jer nije relevantno za analizu u ovom radu, što je zaključeno na osnovu veoma male korelisanosti između obeležja trudnoća i klasne labela abnormalnost krvnog pritiska. Dalje, nedostajuće vrednosti za genetske predispozicije i količinu unosa alkohola po danu dopunjene su srednjom vrednošću s obzirom na to da ne postoje autlajeri (*engl. outlier*) za ova dva obeležja.

U bazi nisu postojale nevalidne vrednosti.

## C. Obuka i formiranje modela

Skup podataka  $x$  je pomoću funkcije *train\_test\_split* iz paketa *sklearn.model\_selection* podeljen na skup za trening ( $x_{train}$ ) koji sadrži 90% uzoraka i skup za test ( $x_{test}$ ) sa 10% uzoraka [3]. U nastavku je izvršena standardizacija obeležja, zbog toga što je za većinu algoritama za klasifikaciju neophodno svesti sva obeležja na isti opseg vrednosti. Obuka modela se vrši na standardizovanom trening skupu, dok se testiranje modela vrši na standardizovanim podacima u test skupu.

Za obuku i evaluaciju modela korišćena su tri algoritma:

- Metoda  $k$  najbližih suseda (*engl. k Nearest Neighbors* - kNN)
- Stabla odluke (*engl. Decision trees*)
- Metode na bazi vektora nosača (*engl. Support Vector Machine* – SVM)

### D. $K$ - Najbližih suseda

kNN predstavlja metodu kasnog učenja koja vrši klasifikaciju nepoznatih uzoraka prema klasnoj pripadnosti bliskih uzoraka iz skupa za obuku. Za implementaciju ovog algoritma neophodan je standardizovan skup za obuku u kom je poznata klasna pripadnost svakog uzorka, zatim celobrojna vrednost parametra  $k$ , a koji predstavlja broj suseda na osnovu kojih se donosi odluka o klasifikaciji nepoznatog uzorka u određenu klasu i metrika za utvrđivanje stepena bliskosti dva vektora obeležja. Prednost ovog algoritma je jednostavna implementacija, dok kao nedostatak možemo navesti obrnutu proporcionalnost tačnosti i brzine i složenosti algoritma, odnosno za veći broj uzoraka, ova metoda je sve tačnija, ali sporija i složenija, dok za manji broj uzoraka performanse mogu drastično opasti [4].

Za potrebe dobijanja optimalnog broja suseda i metrike za računanje rastojanja, isprobane su kombinacije za 1, 2, 3, 4, 5, 6, 7, 8, 9 i 10 suseda, uz 'euclidean', 'manhattan',

'chebyshev' metrike kao specijalne slučajeve  $l_p$  norme koja je pogodna za računanje rastojanja ukoliko vektori obeležja uzimaju realne vrednosti, kao i 'hamming' metrike koja se pretežno koristi za vektore sa celobrojnim vrednostima, pa očekivano u ovom slučaju nije dala dobre rezultate [3].

### E. Stabla odluke

Stablo odluke je česta metoda nadgledanog učenja za klasifikaciju ili regresiju, gde se grananje stabla vrši na osnovu obeležja radi formiranja particija skupa uzoraka. Odabir optimalnog pitanja za particiju čvora doprinosi formiranju stabla, a klasifikacija novih uzoraka se vrši prolaskom kroz stablo do odgovarajućeg lista, gde se najčešće određuje klasa koja preovladava među uzorcima u tom listu. Stablo odluke ima prednosti u jednostavnoj interpretaciji i vizualizaciji, te u maloj osetljivosti na nevažna pitanja. Međutim, može doći do natprilagođenja tokom obuke, a male varijacije u podacima mogu značajno promeniti strukturu stabla, dok fragmentacija podataka može dovesti do gubitka relevantnih informacija, što se može prevazići korišćenjem slučajne šume [4].

Kod klasifikacionih problema, kriterijumi podele mogu se zasnivati na različitim merama kao što su *Dini indeks*, entropija ili  $\chi^2$ -statistika, dok se kod regresionih problema često koriste kriterijumi zasnovani na srednjim kvadratnim ili srednjim apsolutnim greškama između stvarnih i predviđenih vrednosti. Dva najčešće korišćena kriterijuma za klasifikacione probleme su *Dini indeks*, koji meri ukupnu varijansu među klasama, i entropija [4].

*Dini indeks* je mera nečistoće u čvoru stabla odluke i meri koliko su heterogeni uzorci u određenom čvoru prema njihovoj pripadnosti različitim klasama. Manji *Dini indeks* ukazuje na veću čistoću čvora, što znači da su uzorci u tom čvoru pretežno jedne klase [4].

Entropija meri neizvesnost ili neuređenost u čvoru stabla odluke. Visoka entropija znači da su uzorci u čvoru ravnomerno raspoređeni između različitih klasa, dok niska entropija ukazuje na veću homogenost, odnosno dominantnost jedne klase [4].

Pri isprobavanju različitih kombinacija hiperparametara u slučaju stabla odluke, navedeni su *Dini indeks* i entropiju kao kriterijum za utvrđivanje čistoće, odnosno nečistoće čvora (*engl. criterion*), za maksimalan broj grananja isprobane su vrednosti 5, 10, 15 i 20 (*max\_depth*), za broj obeležja koja će stablo razmatrati pri izboru najboljeg pitanja za podelu čvora su navedeni None,  $\log_2$  i  $\sqrt{\text{max\_features}}$  i, konačno, za minimalan broj uzoraka u čvoru nakon podele su isprobane vrednosti od 5 do 35, sa korakom 5 (*min\_samples\_leaf*) [3].

### F. Mašina na bazi vektora nosača

Mašina na bazi vektora nosača (SVM) je klasifikator koji se koristi za binarnu klasifikaciju identifikacijom hiperravnih koja razdvaja uzorke različitih klasa u prostoru obeležja, pri čemu se ciljno formira hiperravan koja obezbeđuje najveću moguću marginu između klasa. U slučajevima kada su uzorci nelinearno separabilni, primenjuje se kernel trik radi preslikavanja uzoraka u višedimenzionalni prostor obeležja, gde postaju linearno razdvojivi, omogućavajući pravilno razdvajanje. Osnovni

parametar C u SVM-u određuje ukupnu toleranciju na grešku klasifikacije, i u zavisnosti od toga kako je definisan, manje ili veće vrednosti ovog parametra određuju manju ili veću toleranciju, odnosno mogućnost da se određen broj uzoraka nađe sa pogrešne strane margine. U slučaju SVM algoritma iz *sklearn.svm* biblioteke koji je korišćen u projektnom zadatku, manja regularizacija (veće vrednosti parametra C) može dovesti do šire margine i mogućnosti da se više tačaka nalazi unutar te margine ili čak na pogrešnoj strani odvojne hiperravni. SVM se može proširiti na klasifikaciju više od dve klase koristeći pristupe "jedan protiv svih" ili "svaki protiv svakog" [4].

Za vrednosti regularizacionog parametra C smo isprobane su sledeće vrednosti: 0.1, 0.2, 0.5, 1, 2, 5 i 10, dok je za izbor najboljeg kernela prosleđen polinomijalni (*poly*), radijalni (*rbf*), linearni (*linear*) i sigmoidni (*sigmoid*) kernel. Zasebno su za vrednosti C i *rbf* kernel isproban hiperparametar *gamma*, koji je uzimao vrednosti *scale* i *auto*, kao i kombinaciju *poly* kernela sa različitim vrednostima za stepen polinoma (*degree*), koji je uzimao vrednosti od 2 do 5 [3].

### G. Kooperativna igra

U današnjim sistemima upravljanja i veštačke inteligencije sve veći značaj se daje kolaboraciji između više međusobno povezanih jedinica, jer one, zajedničkim delovanjem, mogu postići bolje performanse nego ponaosob [5].

Shodno tome, moguće je primeniti pristup zasnovan na kooperativnoj igri. Takva igra je koncipirana na način da može da proučava sisteme sastavljene od više različitih agenata (komponenti), koji pritom međusobno komuniciraju, razmenjuju informacije i donose odluke radi ostvarivanja zajedničkog cilja. Svaki od agenata raspolaže određenim skupom informacija i sam za sebe donosi odluke, ali se kolektivno ponašanje celog sistema ostvaruje zahvaljujući njihovoj međusobnoj koordinaciji. Primeri takvih sistema jesu mreže mobilnih senzora, transportni i energetske sistemi, autonomna vozila i distribuirane računarske mreže. Njihove prednosti jesu prilagodljivost, otpornost na greške i efikasnost, mada, glavni izazov predstavlja postizanje stabilne saradnje i optimalnog grupnog ponašanja [5].

U ovom radu se ideja kooperativne igre posmatra kroz teoriju igara, konkretno, u okviru biomedicinskog problema klasifikacije osoba koje imaju ili nemaju fiziološku vrednost krvnog pritiska. Svaki klasifikator u sistemu može da se posmatra kao racionalni agent (igrač) koji donosi odluke na osnovu sopstvenih informacija, dok se njihova međusobna saradnja (kooperacija) koristi zarad ostvarenja zajedničkog cilja, odnosno povećanja ukupne tačnosti sistema. Time sam model predstavlja primenu ideje kooperativne igre, gde uzajamno delovanje više agenata donosi veći dobitak od pojedinačnih modela. Ovaj pristup uz to što unapređuje detekciju abnormalnosti krvnog pritiska, takođe i omogućava dublje razumevanje načina na koji pojedini algoritmi „komuniciraju“,

razmenjuju informacije i zajednički donose odluke unutar jednog sistema [5].

### H. Mere uspešnosti

Matrica konfuzije je ključni alat za procenu performansi klasifikatora u binarnim klasifikacionim problemima, gde su klase označene kao pozitivna i negativna. Ona prikazuje broj stvarnih pozitivnih (TP) i negativnih (TN) uzoraka, kao i broj lažno pozitivnih (FP) i lažno negativnih (FN) uzoraka. Na osnovu ovih vrednosti, izračunavaju se mere uspešnosti klasifikatora koje pružaju detaljan uvid u njegovu sposobnost identifikacije pozitivnih i negativnih instanci, uzimajući u obzir potrebe specifičnog klasifikacionog problema [4].

Mere uspešnosti klasifikatora uključuju:

1. Tačnost (*accuracy*): Ovo je procenat tačno klasifikovanih uzoraka, odnosno odnos broja ispravno klasifikovanih uzoraka (TP i TN) i ukupnog broja uzoraka (TP, TN, FP i FN) [4].
2. Preciznost (*precision*): Preciznost je procenat tačno pozitivno klasifikovanih uzoraka među svim uzorcima koje je klasifikator označio kao pozitivne, izražen kao odnos broja ispravno pozitivno klasifikovanih uzoraka (TP) i ukupnog broja uzoraka koje je klasifikator označio kao pozitivne (TP i FP) [4].
3. Senzitivnost (odziv, *recall*): Osetljivost je procenat stvarno pozitivno klasifikovanih uzoraka među svim stvarno pozitivnim uzorcima, izražen kao odnos broja ispravno pozitivno klasifikovanih uzoraka (TP) i ukupnog broja stvarno pozitivnih uzoraka (TP i FN) [4].

Za odabir najboljeg modela posmatrana je senzitivnost (*engl. recall*) klasifikatora. Cilj je bio da se pronađe model sa najvećom senzitivnošću, kako bi se dobio što veći procenat bolesnih koji je uspešno otkriven. U nastavku će biti opisan svaki algoritam, uz navođenje hiperparametara koji su se koristili u *GridSearchCV* funkciji u cilju pronalaženja optimalnih, kao i dobijeni rezultati za mere uspešnosti, odnosno za preciznost, tačnost i senzitivnost, respektivno.

## III. REZULTATI

Nakon primene *GridSearchCV* funkcije nad trening skupom, sledeće vrednosti hiperparametara, za svaki pomenuti model, su se izdvojile kao najbolje:


*kNN*: najbolji rezultat je dobijen za 9 suseda i pomoću 'manhattan' metrike, a mere uspešnosti klasifikatora prikazane su u Tabeli I.

Tabela I: Mere uspešnosti kNN klasifikatora

| Mera uspešnosti     | Procenat      |
|---------------------|---------------|
| Preciznost          | 82.0 %        |
| Tačnost             | 79.0 %        |
| <b>Senzitivnost</b> | <b>73.7 %</b> |

Matrica konfuzije *kNN* klasifikatora za ovaj problem prikazana je na Sl.1. Ova matrica sadrži informaciju o uspešnosti klasifikacije na 200 uzoraka iz test skupa koje

klasifikator nije video tokom obuke.



Sl.1. Matrica konfuzije kNN klasifikatora

*Stabla odluke*: najbolja senzitivnost klasifikatora na bazi stabla odluke primenjenog na standardizovanim uzorcima iz skupa za obuku je dobijena za sledeću kombinaciju hiperparametara:


- *criterion*: Dini,
- *max\_depth*: 10,
- *max\_features*: None,
- *min\_samples\_leaf*: 30

Mere uspešnosti ovog algoritma date su u Tabeli II, dok je matrica konfuzije prikazana na Sl.3.

Tabela II: Mere uspešnosti stabla odluke

| Mera uspešnosti     | Procenat      |
|---------------------|---------------|
| Preciznost          | 90.7 %        |
| Tačnost             | 90.0 %        |
| <b>Senzitivnost</b> | <b>88.9 %</b> |

Matrica konfuzije dobijena stablom odluke prikazana je na Sl 3.



Sl.2. Matrica konfuzije stabla odluke kao klasifikatora

Konačno, najbolji rezultati su postignuti korišćenjem sledećih hiperparametara:


- *C*: 1
- *kernel*: rbf
- *gamma*: scale

U Tabeli III se nalaze mere uspešnosti SVM metode primenjene na nezavisnom test skupu.

Tabela III. Mere uspešnosti SVM

| Mera uspešnosti     | Procenat      |
|---------------------|---------------|
| Preciznost          | 73.6 %        |
| Tačnost             | 76.5 %        |
| <b>Senzitivnost</b> | <b>81.8 %</b> |

Matrica konfuzije dobijena upotrebom mašine na bazi vektora nosača prikazana je na Sl 3.



Sl.3. Matrica konfuzije SVM kao klasifikatora


Što se tiče *fusion* modela, koji kombinuje predikcije pojedinačnih klasifikatora koristeći njihove ponderisane senzitivnosti, ostvarena je senzitivnost od 84.8 %. Ovi dobijeni rezultati demonstriraju veću pouzdanost u detekciji stvarno bolesnih ispitanika u odnosu na *kNN* i *SVM*, a blizu je u poređenju sa performansama stabla odluke modela.

U Tabeli IV se nalaze mere uspešnosti SVM metode primenjene na nezavisnom test skupu

Tabela IV: Mere uspešnosti fusion modela

| Mera uspešnosti     | Procenat      |
|---------------------|---------------|
| Preciznost          | 88.4 %        |
| Tačnost             | 87.0 %        |
| <b>Senzitivnost</b> | <b>84.8 %</b> |


Matrica konfuzije dobijena za *fusion* model prikazana je na Sl 4.



SI.4. Matrica konfuzije za *fusion* model

Generalno, matrice konfuzije za sve modele mašinskog učenja, kao i *fusion* modela, pokazuju da su u velikoj meri detektovani ispitanici koji stvarno boluju od kardiovaskularnih bolesti. Takođe, veći broj zdravih ispitanika je detektovano kao bolesno, dok je mali broj ispitanika neotkriveno, što je i najbitnije kod medicinskih problema ovog tipa. Manja je cena detektovati zdravog ispitanika kao bolesnog nego bolesnog ispitanika kao zdravog.

Dodatno, na SI 5. mogu se videti senzitivnosti nad test skupom za sve modele pomenute u ovom radu.



SI.5. Poređenje senzitivnosti pojedinačnih i kooperativnog sistema

Rezultati potvrđuju da *fusion* model uspešno integriše prednosti pojedinačnih klasifikatora u kooperativnom sistemu i dodatno potvrđuje snagu kooperativnog sistema. Dok *kNN* model pokazuje nešto niže rezultate, odnosno senzitivnost od 73.7 %, *fusion* model koristi visoke rezultate *SVM* - a (81.8 %) i stabla odluke (88.9 %), zbog čega je finalni rezultat znatno bolji od najslabijeg člana kooperativnog sistema. Na ovaj način, ograničene su mane *kNN* klasifikatora kroz kolektivnu odluku. Svaki model doprinosi klasifikaciji proporcionalno svom doprinosu u detekciji stvarno bolesnih ispitanika.

#### IV. DISKUSIJA

Opisani projekat prikazuje primenu teorije igara na problem donošenja odluke u biomedicinskim sistemima. Klasifikatori (*KNN*, *SVM* i stabla odluke) su modelovani kao igrači koji međusobno sarađuju unutar kooperativne igre, s ciljem poboljšanja tačnosti klasifikacije. Opisan kooperativni pristup, pored brojnih prednosti, ne

predstavlja optimalno rešenje za sve biomedicinske sisteme. Naime, s obzirom na kombinaciju tri različita algoritma mašinskog učenja, model zahteva značajnu računarsku i energetska efikasnost. Stoga, za sisteme sa ograničenjima u pogledu resursa, kao što su prenosivi medicinski uređaji (npr. mioelektrične proteze), jednostavniji algoritmi bi se pokazali optimalnijim.

S druge strane, biomedicinski sistemi koji ne pokazuju ograničenja u resursima, kooperativni pristup pružao bi pouzdanije predikcije. Ovo je od posebne važnosti u sistemima za predikciju abnormalnosti i bolesti, što je ujedno i tema opisanog projekta.

Analiza rezultata prikazuje jednu od prednosti prikazanog pristupa. Upoređivanjem senzitivnosti pojedinačnih algoritama, uočeno je da *KNN* algoritam postiže najnižu vrednost (73.7%), dok stablo odluke postiže najvišu (89.9%). Senzitivnost nakon kooperativne igre iznosi 84.8%. Ukoliko bi *KNN* algoritam bio korišćen samostalno, njegova niža senzitivnost dovela bi do nepouzdanih dijagnoza, zahtevajući dodatna i nepotrebna testiranja za pacijente, što izaziva stres i nepotrebne troškove. Kooperativna igra ima sposobnost da prevaziđe manu netačnih predikcija pojedinačnih klasifikatora, jer se konačna odluka donosi na osnovu kombinovanog doprinosa svih igrača.

Rezultati pokazuju da senzitivnost kooperativne igre (84.8%) ne dostiže najvišu pojedinačnu vrednost (stablo odluke, 89.9%). Razlog tome leži u relativno niskoj senzitivnosti *KNN* algoritma, koja utiče na konačan ishod konsenzusa. Odabir drugog klasifikatora sa boljom senzitivnošću, popravio bi celokupnu pouzdanost formiranog modela.

#### V. ZAKLJUČAK

Opisani projekat nudi inovativan pristup rešavanju problema klasifikacije zdravih i bolesnih pacijenata korišćenjem teorije igara. Uspostavljanjem kooperativne igre između različitih klasifikatora (*kNN*, *SVM*, stablo odluke), postignuto je prevazilaženje slabosti pojedinačnih algoritama, rezultujući pouzdanijom konačnom predikcijom.

U cilju povećanja celokupne pouzdanosti opisanog pristupa, predlog daljeg rada je testiranje drugih algoritama mašinskog učenja. Fokus bi bio na pronalaženju klasifikatora koji pružaju više pojedinačne vrednosti senzitivnosti, čime bi se postigla tačnija konačna predikcija.

#### REFERENCES

- [1] S. Acharya *et al.*, "Ensemble Learning Approach via Kalman Filtering for a Passive Wearable Respiratory Monitor," *IEEE J. Biomed. Health Inform.*, vol. 23, no. 3, pp. 1022–1031, May 2019, doi: 10.1109/JBHI.2018.2857924.
- [2] "Blood Pressure Data for disease Prediction." Accessed: Nov. 02, 2025. [Online]. Available: <https://www.kaggle.com/datasets/pavanbodanki/blood-pressure>
- [3] S. Raschka, *Machine Learning with PyTorch and Scikit-Learn: Develop machine learning and deep learning models with Python*, 1st ed. Birmingham: Packt Publishing Limited, 2022.
- [4] Tijana Nosek, Branko Brkljač, Danica Despotović, Milan Sečuijski, and Tatjana Lončar-Turukalo, *Praktikum iz mašinskog učenja*, 1st ed. Novi sad: Univerzitet u Novom Sadu, 2020.
- [5] J. S. Shamma, *Cooperative control of distributed multi-agent systems*. Chichester, West Sussex, England: John Wiley & Sons, 2007.